

تابع هدف: تعداد کلاز هایی که در CNF ترو میشود را برمیگرداند. مطلوب ما ماکسیمم کردن این تابع است.

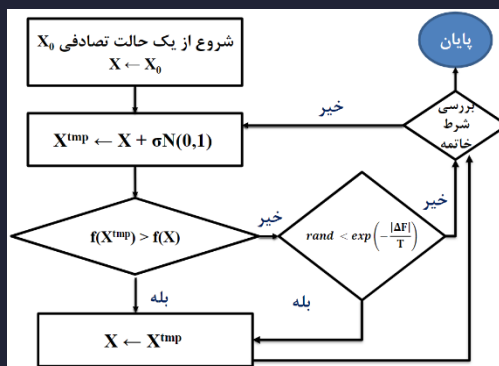
```

3  def countTrueClauses(clauses, variables):
4      count = 0
5      for clause in clauses:
6          for literal in clause:
7              if literal == variables[abs(literal) - 1]:
8                  count += 1
9              break
10     return count

```

الگوریتم simulated annealing:

فلوچارت الگوریتم به این گونه است:



کد:

```

14 def simulatedAnnealing(clauses, varNum, T = 10000, Tmin = 0.00001, Alpha = 0.998):
15     variables = [(random.choice([-1, 1]) * i) for i in range(1, varNum+1)]
16
17
18     E = countTrueClauses(clauses, variables)
19     Eth = len(clauses)
20
21     Elist = [E]
22     Tlist = [T]
23
24     while (T > Tmin and E < Eth):
25         randIndex = random.randint(0, varNum-1)
26
27         newVariables = variables.copy()
28         newVariables[randIndex] = -newVariables[randIndex]
29
30         newE = countTrueClauses(clauses, newVariables)
31
32         if (simulatedAnnealingAccept(newE - E, T)):
33             variables = newVariables
34             E = newE
35             Elist.append(E)
36             Tlist.append(T)
37
38         T *= Alpha
39
40     print("True clauses: " + str(E), "T: " + str(Tlist[0]), "Alpha: " + str(Alpha))
41
42     return variables, Elist
43

```

```

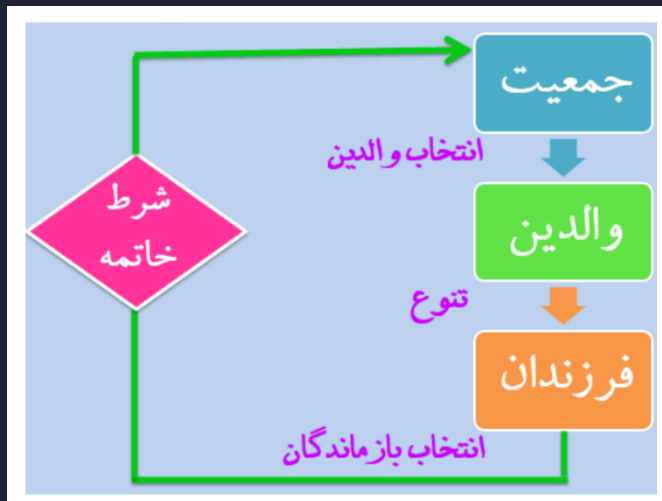
44 def simulatedAnnealingAccept(deltaE, T):
45     if deltaE > 0:
46         return True
47     else:
48         return random.random() < math.exp(-abs(deltaE)/T)
49

```

در این الگوریتم مقادیر T و α را تعیین میکنیم و سپس ابتدا یک $variables$ با مقادیر رندوم در نظر میگیریم و مقدار E را برای آن ذخیره میکنیم.

حال یک فرزند از $variables$ تولید میکنیم به طوری که یکی از متغیرها نقیض شود و مقدار E را برای فرزند محاسبه میکنیم. سپس با استفاده از تابع $accept$ تعیین میکنیم که این فرزند را نگه داریم یا نه. در صورتی که E آن بیشتر باشد قبولش میکنیم و در صورتی که نباشد با یک احتمالی ممکن است قبولش کنیم (برای فرار از $local\ optimum$).

الگوریتم genetic:



در این الگوریتم با استفاده از جمعیتی که در اختیار داریم چندین والد انتخاب میکنیم و سپس فرزندان آنها را به جمعیت جدید اضافه میکنیم و در انتها در جمعیت جدید بازماندگان را انتخاب میکنیم. و اگر شرط خاتمه $satisfy$ نشد به $iteration$ بعدی میرویم.

کد:

در اینجا انتخاب والدین را بر اساس رتبه بندی و انتخاب بازماندگان را بر اساس شایسته سالاری انجام میدهیم.

```

107 def crossover(parent1, parent2, Pc):
108     randIndex = random.randint(0, len(parent1)-1)
109
110     child1 = list(parent1).copy()
111     child2 = list(parent2).copy()
112
113     if random.random() < Pc:
114         child1 = list(parent1[:randIndex] + parent2[randIndex:])
115         child2 = list(parent2[:randIndex] + parent1[randIndex:])
116
117     return child1, child2
118
119 def Mutation(parent, Pm):
120     randIndex = random.randint(0, len(parent)-1)
121
122     child = parent.copy()
123
124     if random.random() < Pm:
125         child[randIndex] = -child[randIndex]
126
127     return tuple(child)
  
```

```

53 def genetic(clauses, varNum, MaxIteration = 2000, PopulationSize = 10, Pc = 0.8, Pm = 0.1):
54     population = {}
55
56     while len(population) < PopulationSize:
57         variables = [(random.choice([-1, 1]) * i) for i in range(1, varNum+1)]
58         E = countTrueClauses(clauses, variables)
59         population[tuple(variables)] = E
60
61     population = dict(sorted(population.items(), key=lambda item: item[1]))
62
63     Emax = list(population.values())[-1]
64     Eth = len(clauses)
65     Elist = [Emax]
66
67     iteration = 0
68     while (iteration < MaxIteration and Emax < Eth):
69         newPopulation = {}
70
71         for i in range(PopulationSize//2):
72             parents = random.choices(list(population.keys()),
73                                     range(PopulationSize, 0, -1),
74                                     k = 2)
75
76             child1, child2 = crossOver(parents[0], parents[1], Pc)
77
78             child1 = Mutation(child1, Pm)
79             child2 = Mutation(child2, Pm)
80
81             E1 = countTrueClauses(clauses, child1)
82             E2 = countTrueClauses(clauses, child2)
83
84             newPopulation[child1] = E1
85             newPopulation[child2] = E2
86
87         newPopulation.update(population)
88
89         population = dict(sorted(newPopulation.items(),
90                                 key=lambda item: item[1], reverse=True)[:PopulationSize])
91
92
93         Emax = list(population.values())[-1]
94         Elist.append(Emax)
95
96         iteration += 1
97
98     print("True clauses: " + str(Emax), "MaxIteration: " + str(MaxIteration),
99           "PopulationSize: " + str(PopulationSize),
100          "Pc: " + str(Pc), "Pm: " + str(Pm))
101
102     variables = list(list(population.keys())[-1])
103
104     return variables, Elist

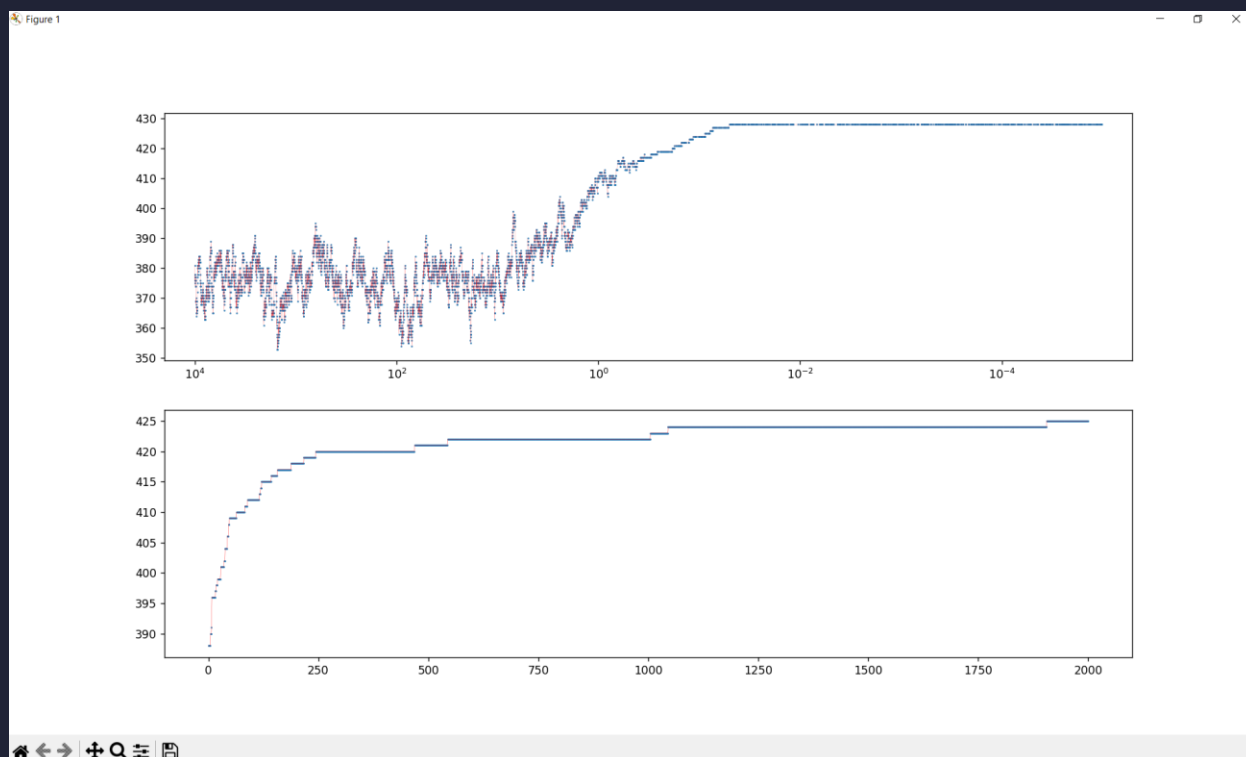
```

مقایسه دو الگوریتم:

در الگوریتم simulated annealing چون در ابتدا T بزرگ است شرط $random < e^{\frac{-\Delta E}{T}}$ با احتمال زیادی True میشود در نتیجه الگوریتم اجازه میدهد به E های بدتر هم برود اما هنگامی که T کمتر از ۱۰ میشود E هایی که بیشتر میشود را قبول میکند.


اما در الگوریتم genetic به خاطر داشتن جمعیت، تنوع بهتر حفظ میشود و با چندبار اجرا با انتخاب شایسته سالار به نتیجه مطلوب نزدیک میشویم.

```
SimulatedAnnealing T: 10000 Alpha: 0.998
True clauses: 429
variables: [-1, -2, 3, 4, -5, 6, -7, 8, 9, 10, 11, -12, -13, -14, 15, 16, -17, -18, -19, -20, 21, -22, -23, -24, -25, -26, -27, 28, 29, -30, 31, -32, 33, -34, 3
5, -36, -37, 38, -39, 40, -41, 42, 43, 44, 45, 46, -47, -48, 49, 50, -51, 52, -53, -54, -55, -56, -57, -58, 59, 60, -61, 62, 63, -64, 65, 66, 67, -68, 69, -70,
-71, 72, -73, -74, -75, -76, 77, 78, 79, -80, -81, -82, -83, 84, -85, 86, -87, -88, -89, 90, -91, -92, 93, 94, 95, 96, 97, -98, 99, 100]
Genetic MaxIteration: 2000 PopulationSize: 10 Pc: 0.8 Pm: 0.1
True clauses: 426
variables: [-1, -2, 3, 4, -5, 6, 7, 8, -9, 10, -11, -12, 13, 14, 15, 16, -17, -18, -19, 20, 21, -22, 23, 24, -25, -26, -27, 28, 29, 30, 31, -32, -33, -34, -35,
-36, -37, -38, 39, 40, 41, 42, 43, 44, 45, 46, -47, -48, -49, -50, -51, 52, -53, -54, 55, -56, -57, -58, 59, 60, 61, -62, -63, 64, -65, -66, 67, -68, 69, -70, 7
1, 72, -73, -74, -75, 76, 77, 78, 79, 80, 81, -82, -83, 84, 85, -86, 87, -88, -89, 90, -91, -92, -93, 94, 95, -96, 97, -98, -99, 100]
```



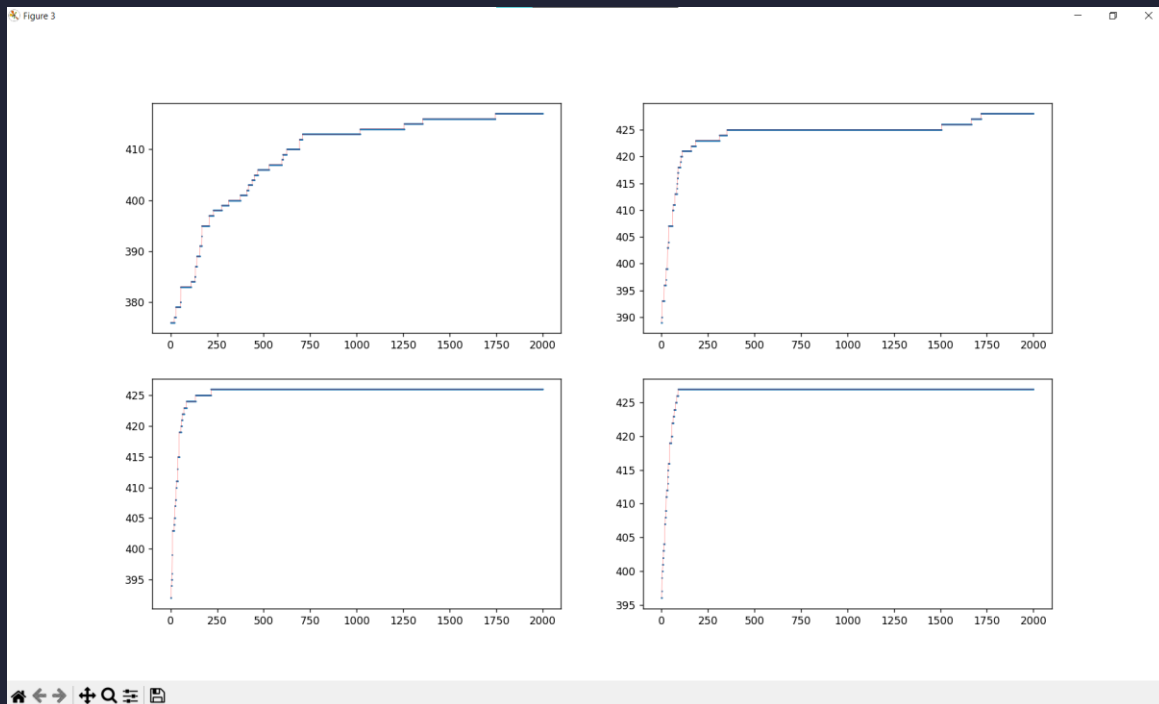
مقایسه های داخل الگوریتمی:

در الگوریتم simulated annealing با زیاد کردن T در ابتدای الگوریتم بیشتر به E های کمتر شانس میدهد.



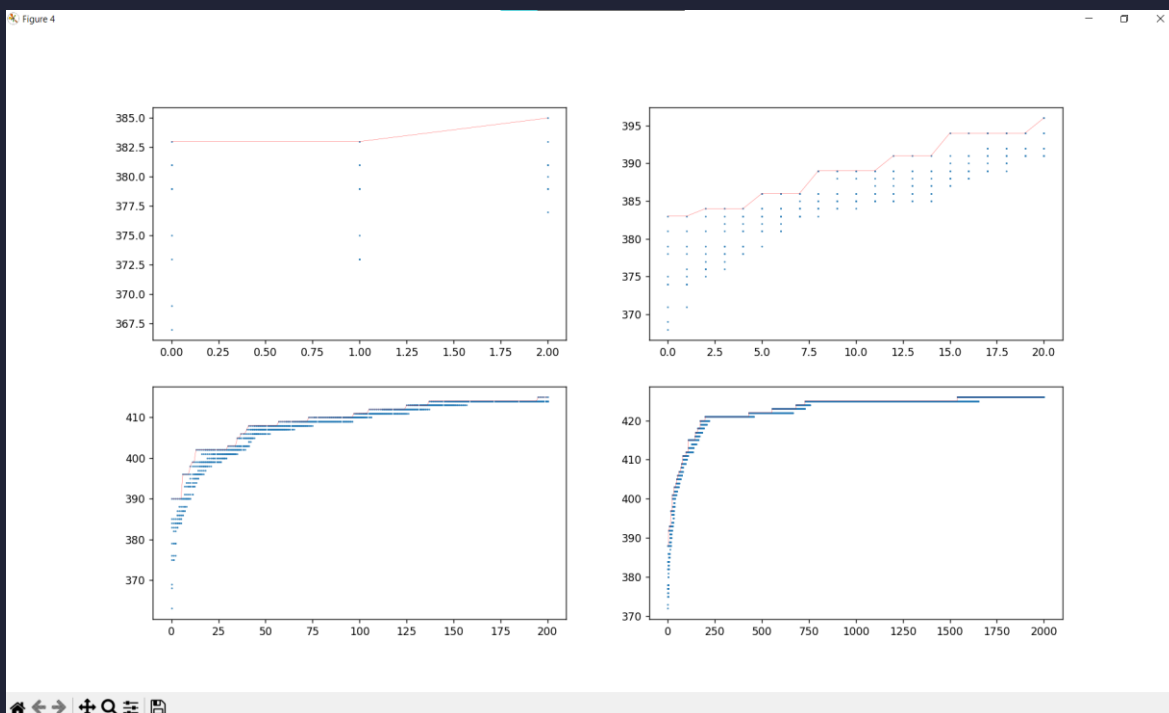
$$T=1, T=10, T=100, T=1000$$

در الگوریتم genetic هنگامی که جمعیت را افزایش می‌دهیم چون تنوع بیشتر میشود زودتر به حالت مطلوب میرسد



PopulationSize=2, PopulationSize=20, PopulationSize=200, PopulationSize=2000

هرچه iteration بیشتر میشود تنوع به سمت حالت مطلوب همگرا تر میشود.



Iteration=2, iteration=20, iteration=200, iteration=2000